

Реферат до семестрового проекту

Тема: Статистичний аналіз потокових даних (Histogram)

Виконали: Сердюк Софія та Бушуєва Дарія. Спеціальність "Статистика"

Вступ

Дана робота присвячена розробці системи статистичного аналізу великих масивів даних. Основною особливістю проекту є реалізація принципу потокової обробки (Streaming Processing), що дозволяє накопичувати статистику без зберігання всієї вибірки в оперативній пам'яті. Це забезпечує ефективність алгоритму з часовою складністю $O(1)$ на кожне нове число та константними витратами пам'яті $O(M)$, де M — кількість інтервалів гістограми.

1 Організація та структура проекту

Проект розроблено як систему для накопичення та аналізу статистичних даних, що функціонує за принципом потокової обробки. Архітектура побудована на паралельній реалізації алгоритмів мовами C та C++ , що дозволяє забезпечити як високу швидкість виконання на низькому рівні, так і зручність використання через об'єктно-орієнтовані інтерфейси.

1.1 Розподіл за мовними модулями

Проектна ієрархія розділена на два основні модулі, кожен з яких є автономним, але використовує єдину математичну логіку.

- **Модуль Histogram_C (Процедурний підхід):**

- **Histogram_c.h** — визначає структуру даних **Histogram** та оголошує набір функцій для ініціалізації об'єкта, динамічного керування пам'яттю та налаштування параметрів гістограми.
- **Histogram_c.c** — реалізує основний функціонал: читування даних із текстових і бінарних файлів, арифметичний розрахунок статистичних показників (середнє, медіана, дисперсія тощо) та перевірку статистичних гіпотез за критерієм Пірсона.
- **histogram_test.c** — забезпечує користувацький інтерфейс через консольне меню та містить генератори вибірок для різних законів розподілу, що необхідно для тестування коректності розрахунків.

- **Модуль Histogram_CPP (Об'єктно-орієнтований підхід):**

- **Histogram_cpp.h** — описує клас **Histogram_cpp** у власному просторі імен **cpp_hist**. Клас інкапсулює дані про частоти та межі інтервалів, надаючи методи для додавання значень та отримання результатів аналізу.
- **Histogram_cpp.cpp** — містить реалізацію методів класу. Для роботи з файлами та формування підсумкових звітів тут використовуються можливості стандартної бібліотеки C++ (потоки введення-виведення).
- **Histogram_test.cpp** — реалізує користувацький інтерфейс для об'єктно-орієнтованого модуля за допомогою консольного меню. Включає механізми генерації випадкових вибірок на основі стандартних засобів C++ для перевірки працездатності методів класу.
- **Histogram_cross_test.cpp** — ключовий елемент верифікації системи. Він інтегрує обидва модулів в одному середовищі, використовуючи **extern "C"** для виклику функцій мови C, і порівнює результати обчислень обох версій на однакових даних.

2 Взаємодія з даними та формати файлів

Проект підтримує три основні сценарії роботи з інформацією, що дозволяє обробляти як поодинокі значення, так і великі масиви даних (вибірки) без надмірних витрат оперативної пам'яті.

- **Консольне введення:** Реалізовано інтерактивний режим у методі **addFromConsole**. Користувач може вводити числа по одному, а програма миттєво обчислює індекс і оновлює частоти у відповідних інтервалах гістограми, що зручно для ручного тестування.

- **Текстові файли (.txt):** Передбачено читування масивів даних через метод **addFromTextFile**. Числа, розділені пробілами або символами переходу на новий рядок, зчитуються по черговому.

- **Бінарні файли (.dat):** Найбільш ефективний спосіб взаємодії, реалізований у методі **addFromBinaryFile**. Дані зчитуються побайтово через **reinterpret_cast<char*>** безпосередньо у внутрішньому представленні (**double**), що забезпечує максимальну швидкість обробки Big Data та мінімізує похибки конвертації.

Автоматична генерація тестових даних: Для перевірки роботи критерію Пірсона в модулях тестування реалізовано автоматичне створення вибірок, де користувач повністю контролює параметри генерації. Через консольний інтерфейс вручну задаються межі діапазону, кількість значень у гістограмі, тип стратегії обробки крайових значень та характер розподілу (це може бути один із 5 вбудованих теоретичних законів чи абсолютно випадковий набір чисел). Програма генерує масив даних за вказаними налаштуваннями й запише їх у текстовий чи бінарний файл. Після цього обчислювальний блок зчитує створені файли у звичайному пакетному режимі. Це дозволяє надійно перевірити алгоритм: якщо ми згенерували розподіл за обраними параметрами, критерій повинен чітко підтвердити саме цю математичну модель і відхилити всі інші.

Стратегії обробки крайових значень: Оскільки вхідний потік даних може містити аномалії, які не потрапляють у заданий фіксований діапазон системи комірок $[min_hist; max_hist]$, у методі **addNumber** впроваджено дві стратегії (вибір здійснюється користувачем через функцію **askUserStrategy**):

1. **Discard (Ігнорування):** значення за межами діапазону повністю відкидаються, не впливаючи на лічильники комірок та загальну статистику N , що дозволяє очистити вибірку від грубих викидів.
2. **Clamp (Обрізання):** значення, менші за мінімум, додаються до першого інтервалу, а більші за максимум — до останнього. Це дозволяє зберегти загальний обсяг вибірки N незмінним.

3 Методи аналізу та перевірки статистичних гіпотез

На основі базових параметрів та накопичених частот система виконує повний статистичний аналіз вибірки. Обчислення виконуються у два послдовні етапи: розрахунок показників описової статистики та перевірка гіпотез про закон розподілу за допомогою критерію Пірсона.

3.1 Описова статистика та моменти розподілу

На основі сформованого набору інтервалів програма обчислює основні числові характеристики вибірки, які дозволяють оцінити центр, розсіювання та форму розподілу даних.

1. **Вибіркове середнє ($\bar{x}$)**

- **Зміст:** Визначає середнє арифметичне значення всієї вибірки. Оскільки після розподілу по комірках точні початкові числа втрачаються, ми використовуємо принцип заокруглення, що всі значення всередині кожного інтервалу дорівнюють його середині. Через це розрахунок будеться як «зважене середнє»: кожна середина інтервалу множиться на кількість чисел, що в нього потрапили.

- **Формула:**

$$\bar{x} = \frac{1}{N} \sum_{i=0}^{M-1} n_i \cdot x_i^*$$

де:

- N — загальний обсяг вибірки (кількість усіх опрацьованих чисел);
- M — загальна кількість інтервалів (комірок) у гістограмі;
- i — порядковий індекс поточного інтервалу (змінюється від 0 до $M - 1$);
- n_i — абсолютна частота (кількість елементів), що потрапили в i -й інтервал;
- x_i^* — центральна точка (середина) i -го інтервалу.

- **Зв'язок із кодом:** Обчислення реалізовано у функції **histMean(h)**. Алгоритм за один прохід циклу по всьому набору інтервалів додає до загальної суми добутки частот **h->frequency[i]** на результат функції **histGetMidpoint(h, i)**. Отримана сума ділиться на загальний обсяг вибірки **h->total_count**.

2. **Медіана (Me)**

- **Зміст:** Значення ознаки, яке ділить навпіл площу гістограми та всю вибірку. Половина опрацьованих чисел є меншими за медіану, а інша половина — більшими. Оскільки точні початкові числа не зберігаються, алгоритм спочатку шукає інтервал, в якому міститься середина вибірки, а потім за допомогою математичної пропорції (лінійної інтерполяції) вираховує точне значення медіани всередині цього інтервалу.

- **Формула:**

$$Me = L + h \cdot \frac{\frac{N}{2} - S_{prev}}{n_{me}}$$

де:

- L — нижня (ліва) межа медіанного інтервалу;
- h — ширина одного інтервалу гістограми;
- N — загальний обсяг вибірки (кількість усіх опрацьованих чисел);
- S_{prev} — накопичена частота (сумарна кількість чисел) у всіх комірках, що передують медіанній;
- n_{me} — абсолютна частота (кількість чисел) безпосередньо всередині медіанного інтервалу.

- **Зв'язок із кодом:** Реалізовано у функції **histMedian(h)**. Програма запускає цикл, який послдовно додає частоти комірок у змінну **cumulative**. Щойно **cumulative** досягає або перевищує половину вибірки **half (N/2)**, пошук зупиняється. Поточний індекс визначає ліву межу L та власну частоту комірки **h->frequency[i] (n_{me})**, а значення S_{prev} обчислюється як **cumulative - h->frequency[i]**. На основі цих змінних функція повертає точний результат.

3. **Вибіркова дисперсія (S^2) та середньоквадратичне відхилення (S)**

- **Зміст:** Характеризують ступінь розсіяння (розкиду) чисел навколо їхнього середнього значення. Дисперсія обчислює цей розкид у квадратних одиницях, а середньоквадратичне відхилення (стандартне відхилення) повертає метрику до початкових одиниць вимірювання (вибірки через добування квадратного кореня. Для усунення систематичного заниження розкиду при роботі з обмеженими вибірками у формулі застосовано неспінену оцінку (виправлення Бесселя).

- **Формула:**

$$S^2 = \frac{1}{N - 1} \sum_{i=0}^{M-1} n_i \cdot (x_i^* - \bar{x})^2, \quad S = \sqrt{S^2}$$

де:

- $N - 1$ — кількість ступенів свободи (знаменник, зменшений на одиницю за виправленням Бесселя);
- M — загальна кількість інтервалів у гістограмі;
- i — порядковий індекс поточного інтервалу
- n_i — абсолютна частота (кількість елементів) в i -му інтервалі;
- x_i^* — середина i -го інтервалу;
- $\bar{x}$ — вибіркове середнє.

- **Зв'язок із кодом:** Обчислення дисперсії реалізовано у функції **histVariance(h)**, а стандартного відхилення — у **histDev(h)**. Алгоритм **histVariance(h)** спочатку отримує середнє через **histMean(h)**, а потім у циклі рахує суму квадратів відхилень центрів комірок від цього середнього, помножену на частоту комірки **h->frequency[i]**. Фінальна сума ділиться на **h->total_count - 1**. У функції впроваджено захисний оператор: якщо обсяг вибірки $N \leq 1$, ділення не виконується, а функція повертає 0.0. Функція **histDev(h)** просто повертає квадратний корінь (**sqrt**) від результату дисперсії.

4. **Мода (Mo)**

- **Зміст:** Значення, яке найчастіше зустрічається в досліджуваній вибірці. В умовах групуваних даних та потокової обробки ми не знаємо точного лідера серед початкових чисел, тому модою вважається центральна точка модального інтервалу — комірки, яка накопичила найбільшу кількість значень.

- **Формула:**

$$Mo = x_{idx}^*, \quad \text{де } idx = \arg \max_i (n_i)$$

де:

- idx — порядковий індекс комірки, яка має максимальну частоту;
- n_i — кількість елементів в i -му інтервалі;
- x_{idx}^* — середина знайденого модального інтервалу.

- **Зв'язок із кодом:** Розрахунок виконується у функції **histMode(h)**. Алгоритм спочатку приймає частоту першої комірки **h->frequency[0]** за максимальну, а потім у циклі проходить по всіх інших інтервалах від 1 до $M - 1$. Якщо знаходиться комірка з більшим значенням лічильника, програма оновлює максимум і фіксує її індекс у змінній **mode_idx**. Після завершення циклу функція повертає значення геометричного центру цього інтервалу через виклик **histGetMidpoint(h, mode_idx)**.

5. **Показники форми: Коефіцієнти асиметрії (γ_1) та ексцесу (γ_2)**

- **Зміст:** Оцінюють геометричний профіль розподілу, показуючи, як саме форма отриманої гістограми відрізняється від ідеального симетричного "дзвона"(нормального розподілу).

- **Асиметрія (γ_1)** вимірює «скошеність» графіка. Оскільки у формулі використовується третій степінь, він зберігає знаки мінус та плюс для нормованих відхилень комірок від середнього. Якщо більшість даних згруповані ліворуч, а праворуч тягнеться довгий подинокий «хвіст» із рідкісних комірок, то великі додатні відхилення переважають мінуси, і γ_1 буде додатним. Якщо хвіст тягнеться ліворуч — від'ємним. У симетричному розподілі додатні та від'ємні відхилення повністю взаємознищуються, давши нуль.
- **Ексцес (γ_2)** вимірює «гостроту» піка. Тут використовується четвертий степінь, тому будь-яке відхилення від середнього (і вліво, і вправо) стає додатним числом. Якщо у вибірці є дуже багато значень на краях розподілу (так звані «важкі хвости» гістограми), четвертий степінь виросте колосально, і коефіцієнт буде високим. Константа -3.0 потрібна для порівняння: у сучасно нормального розподілу цей вираз дорівнює 3, тому віднімання трійки робить його ексцес нульовим. Якщо підсумковий $\gamma_2 > 0$ — пік розподілу є гострим, якщо $\gamma_2 < 0$ — плоским.

- **Формули:**

$$\gamma_1 = \frac{1}{N} \sum_{i=0}^{M-1} n_i \cdot \left(\frac{x_i^* - \bar{x}}{S} \right)^3, \quad \gamma_2 = \left[\frac{1}{N} \sum_{i=0}^{M-1} n_i \cdot \left(\frac{x_i^* - \bar{x}}{S} \right)^4 \right] - 3.0$$

де:

- N — загальний обсяг вибірки;
- M — загальна кількість інтервалів у гістограмі;
- i — порядковий індекс поточного інтервалу (від 0 до $M - 1$);
- n_i — кількість елементів в i -му інтервалі;
- x_i^* — середина i -го інтервалу;
- $\bar{x}$ — вибіркове середнє;
- S — стандартне відхилення вибірки;
- $\frac{x_i^* - \bar{x}}{S}$ — нормоване відхилення середини інтервалу від середнього значення.

- **Зв'язок із кодом:** Обчислення асиметрії реалізовано у функції **histSkewness(h)**, а ексцесу — у **histKurtosis(h)**. Обидва алгоритми спочатку викликають функції **histMean(h)** та **histDev(h)** для отримання параметрів $\bar{x}$ та S . Потім у циклі програма обчислює нормоване відхилення для кожної комірки, підносить його до потрібного степеня, множить на вагу комірки **h->frequency[i]** та накопичує суму. У функції ексцес з отриманого результату додатково віднімається 3.0. Якщо розкид даних відсутній ($S = 0$), функції повертають 0.0, уникаючи критичної помилки ділення на нуль.

6. **Коефіцієнт варіації (V)**

- **Зміст:** Відносна міра розсіяння даних, що виражається у відсотках. Вона дозволяє порівнювати мінливість абсолютно різних явищ, а також оцінювати однорідність даних: якщо $V < 33\%$, вибірка вважається однорідною і стабільною, а якщо більша — дані сильно розкидані й неоднорідні.

7. **Формула:**

$$V = \frac{S}{\bar{x}} \cdot 100\%$$

де:

- S — стандартне відхилення вибірки, що показує абсолютний масштаб розкиду;

- $\bar{x}$ — вибіркове середнє значення, що виступає точкою відліку та базовим масштабом вибірки.

8. **Зв'язок із кодом:** Реалізовано у функції **variation_coeff(h)**. Програма послдовно викликає функції **histMean(h)** та **histDev(h)** для отримання значень $\bar{x}$ та S . Після цього здійснюється ділення відхилення на середнє із масштабуванням результату на 100.0. У коді реалізовано важливий безпековий оператор: якщо вибіркове середнє дорівнює нулю ($\bar{x} = 0$), функція миттєво повертає 0.0.

3.2 Перевірка статистичних гіпотез за критерієм χ^2 Пірсона

Для встановлення відповідності між отриманим емпіричним розподілом та теоретичними математичними моделями в системі розроблено критерій згоди χ^2 .

- **Математичний зміст критерію χ^2 Пірсона:**

Метод дозволяє строго перевірити, чи схожі реальні дані на якусь математичну модель (наприклад, на нормальний розподіл). Логіка критерію базується на порівнянні: ми беремо фактичну кількість чисел у комірки (n_i) і порівнюємо її з теоретичною очікуваною кількістю (E_i), яка мала б там бути, якщо гіпотеза була ідеально правильною. Якщо різниця між фактом і теорією в усіх комірках мінімальна, то підсумковий бал «несхожості» (χ^2_{exp}) буде близьким до нуля, і ми робимо висновок, що модель підходить. Якщо ж реальні стовпчики сильно відрізняються від теоретичних, значення χ^2_{exp} виросте, і гіпотеза відхиляється.

- **Формула:**

$$\chi^2_{exp} = \sum_{i=0}^{M-1} \frac{(n_i - E_i)^2}{E_i}, \quad \text{де } E_i = N \cdot p_i$$

де:

- χ^2_{exp} — значення статистики критерію Пірсона;
- M — загальна кількість інтервалів у гістограмі;
- i — порядковий індекс поточного інтервалу (від 0 до $M - 1$);
- n_i — кількість елементів в i -й комірки;
- E_i — очікувана (теоретична) частота для i -ї комірки;
- N — загальний обсяг вибірки;
- p_i — теоретична ймовірність того, що випадкове число потрапить у межі i -го інтервалу $[x_i; x_{i+1})$.

- **Реалізовані моделі та обчислювальна специфіка:**

1. **Нормальний розподіл (histTestPearsonNormal)**

- **Зміст та логіка:** Перевіряє, чи мають дані форму класичного симетричного «дзвона» Гауса. Оскільки нормальний розподіл є неперервним, теоретична ймовірність для кожної комірки — це площа під кривою розподілу на ділянці від лівої межі інтервалу x_i до правої межі x_{i+1} . Щоб знайти цю площу без громіздкого чисельного інтегрування, програма використовує вбудовану функцію помилок **erf**.

- **Формула:**

$$p_i = 0.5 \cdot \left[\operatorname{erf} \left(\frac{x_{i+1} - \bar{x}}{\sqrt{2}} \right) - \operatorname{erf} \left(\frac{x_i - \bar{x}}{\sqrt{2}} \right) \right]$$

де x_i та x_{i+1} — ліва та права фізичні межі поточного інтервалу, $\bar{x}$ — вибіркове середнє, S — стандартне відхилення, а **erf** — стандартна функція помилок.

- **Зв'язок із кодом:** Реалізовано у функції **histTestPearsonNormal(h)**. Алгоритм автоматично розраховує параметри $\bar{x}$ та S за поточною вибіркою, після чого в циклі обчислює нормовані межі кожного стовпчика, знаходить теоретичну ймовірність p_i , отримує очікувану частоту **expected (E_i)** і накопичує суму квадратів відхилень у змінній **chi_square**. Порожні комірки (**h->frequency[i] == 0**) ігноруються для стабільності розрахунків.

2. **Рівномірний розподіл (histTestPearsonUniform)**

- **Зміст та логіка:** Перевіряє, чи розподілені числа по всьому діапазону абсолютно однаково (без явних піків чи спадів). За цієї моделі в кожну комірку має потрапити однакова кількість елементів. Теоретична ймовірність для будь-якого інтервалу є однаковою і дорівнює $1/M$.

- **Формула:**

$$E_i = \frac{N}{M}$$

де E_i — очікувана частота для кожної комірки, N — загальний обсяг вибірки, M — кількість інтервалів.

- **Зв'язок із кодом:** Обчислення виконує функція **histTestPearsonUniform(h)**. Оскільки очікувана частота **expected_freq** однакова для всіх стовпців, вона розраховується один раз перед циклом як **(double)h->total_count / h->M**, що значно прискорює роботу алгоритму в потоковому режимі.

3. **Експоненціальний розподіл (histTestPearsonExponential)**

- **Зміст та логіка:** Перевіряє, чи згасають частоти даних із часом або ростом аргументу за законом спадної експоненти. Модель описується параметром інтенсивності λ , який обернено пропорційний середньому значенню вибірки. Ймовірність p_i обчислюється як різниця значень теоретичної кумулятивної функції розподілу на межах інтервалу.

- **Формула:**

$$p_i = e^{-\lambda x_i} - e^{-\lambda x_{i+1}}, \quad \text{де } \lambda = \frac{1}{\bar{x}}$$

де x_i та x_{i+1} — ліва та права межі інтервалу, e — основа натурального логарифма, а λ — параметр інтенсивності.

- **Зв'язок із кодом:** Розрахунок покладено на функцію **histTestPearsonExponential(h)**. Програма перевіряє умову $\bar{x} > 0$ (оскільки експоненціальний закон визначений лише для додатних чисел) і визначає **lambda = 1.0 / m** (**m** = **histMean(h)**). Теоретична ймовірність обчислюється через функцію **exp()**, після чого визнається внесок комірки в загальну суму **chi_square**.

4. **Розподіл Пуассона (histTestPearsonPoisson)**

- **Зміст та логіка:** Моделює потік рідкісних випадкових подій. Оскільки розподіл Пуассона є дискретним (приймає лише ціліми числами 0, 1, 2, ...), а наша гістограма побудована на неперервних інтервалах, програма виконує адаптацію: за значення аргументу k приймається округлена до найближчого цілого середина поточного інтервалу. Для заоблігання обчислювальному переповненню (**overflow**) при знаходженні факторіала $k!$ розрахунок ймовірності переведено в логарифмічну шкалу.

- **Формула:**

$$p(k) = \exp \left(k \cdot \ln(\lambda) - \lambda - \ln(k!) \right), \quad \text{де } k = \operatorname{round}(x_i^*) \text{ та } \lambda = \bar{x}$$

де k — округлена середина інтервалу, λ — параметр розподілу (що дорівнює середньому вибіркового), а $\ln(k!)$ — логарифм факторіала.

- **Зв'язок із кодом:** Реалізовано у функції **histTestPearsonPoisson(h)**. Замість обчислення прямого факторіала алгоритм викликає допоміжну функцію **lgamma_approx(k + 1)**, яка через суму логарифмів знаходить значення $\ln(k!)$. Вираз **log_p = k * log(λ) - λ - lgamma_approx($k + 1$))** дозволяє безпечно працювати навіть з дуже великими значеннями частот і центрів комірок.

5. **Біноміальний розподіл (histTestPearsonBinomial)**

- **Зміст та логіка:** Описує кількість успіхів у серії з n незалежних випробувань (де кожна подія має лише два результати (наприклад успіх чи невдача)). Кількість успіхів k прив'язується до структури нашої гістограми й дорівнює $M - 1$ (де M — загальна кількість комірок). Ймовірність успіху p_{prob} оцінюється на основі даних, де саме перебуває вибіркове середнє відносно меж всієї гістограми. Тут також використовується логарифмування для обчислення числа поєднань C_n^k , щоб уникнути переповнення типів даних.

- **Формула:**

$$p(k) = \exp \left(\ln C_n^k + k \cdot \ln(p_{prob}) + (n - k)$$